

UNIVERSIDAD DEL VALLE DE GUATEMALA

Data Science

Sección 30



Proyecto 1

Humberto Alexander de la Cruz - 23735

Daniel Oswaldo Juárez - 23709

Nicolle Alexandra Gordillo - 22246

GUATEMALA, 19 de Julio de 2026

Metadatos del Conjunto de Datos

- **Fecha de extracción:** 16 de julio de 2026
- **Fuente de los datos:** Portal web del Ministerio de Educación de Guatemala
http://www.mineduc.gob.gt/BUSCAESTABLECIMIENTO_GE/
- **Versión del conjunto limpio:** Versión 1.0 (Archivo: diversificado_limpio.csv)

Diccionario de Variables

Variable	a. Descripción de la variable	b. Tipo de dato	c. Dominio permitido	d. Valores posibles	e. Tratamiento aplicado durante la limpieza	f. Variable derivada
CODIGO	Código único del establecimiento escolar.	Texto	##-##-####-##	11,867 códigos únicos.	Se eliminaron espacios en blanco y los marcadores vacíos se convirtieron a NA.	No (Original)
DISTRITO	Código oficial de distrito escolar.	Texto	##-### o ##-##-####	1,678 distritos.	Códigos truncos (##-) fueron pasados a NA.	No (Original)

DEPARTAMENTO	Departamento administrativo original.	Categoría	22 deptos + CIUDAD CAPITAL	23 categorías.	Estandarización a MAYÚSCULAS sin tildes.	No (Original)
MUNICIPIO	Municipio o zona de la capital.	Categoría	Nombres geográficos	352 categorías.	Estandarización a MAYÚSCULAS sin tildes.	No (Original)
ESTABLECIMIENTO	Nombre de la institución.	Texto	Texto libre	6,297 nombres.	Eliminación de comillas envolventes, espacios dobles e invisibles.	No (Original)
DIRECCION	Dirección física de la sede.	Texto	Texto libre	7,425 direcciones.	Extracción de fechas incrustadas a otra columna y normalización de espacios.	No (Original)
TELEFONO	Número(s) de contacto (crudo).	Texto	Libre (dígitos y caracteres)	6,570 valores.	Cadenas espurias o vacías pasadas a NA. Se conservó el texto original.	No (Original)

SUPERVISOR	Nombre del supervisor asignado.	Texto	Texto libre	1,280 nombres.	Marcadores de ausencia pasados a NA. Limpieza de espacios.	No (Original)
DIRECTOR	Nombre del director a cargo.	Texto	Texto libre	5,511 nombres.	Guiones (--, ---) reemplazados por NA computacionales.	No (Original)
NIVEL	Nivel escolar de la base descargada.	Categoría	DIVERSIFICADO	1 categoría.	Conservado como variable de control y estandarizado a mayúsculas.	No (Original)
SECTOR	Sector institucional o financiamiento.	Categoría	OFICIAL, PRIVADO, MUNICIPAL, COOPERATIVA	4 categorías.	Estandarización a MAYÚSCULAS sin tildes.	No (Original)
AREA	Tipo de área geográfica urbana o rural.	Categoría	URBANA, RURAL	2 categorías.	Valor inválido ("SIN ESPECIFICAR") reclasificado como NA.	No (Original)

STATUS	Estatus operativo actual.	Categoría	Catálogo de estatus MINEDUC	5 categorías (ej. ABIERTA, CERRADA DEFINITIVAMENTE).	Estandarización a MAYÚSCULAS sin tildes.	No (Original)
MODALIDAD	Modalidad lingüística de enseñanza.	Categoría	MONOLINGÜE, BILINGÜE	2 categorías.	Estandarización a MAYÚSCULAS sin tildes.	No (Original)
JORNADA	Jornada del plan educativo.	Categoría	Catálogo de jornadas	6 categorías (ej. MATUTINA, NOCTURNA).	Estandarización a MAYÚSCULAS sin tildes.	No (Original)
PLAN	Esquema presencial o a distancia.	Categoría	Catálogo de planes	13 categorías (ej. DIARIO(REGULAR)).	Eliminación de tildes para evitar categorías duplicadas por escritura.	No (Original)

DEPARTAMENTAL	Dirección Departamental (DIDEDUC).	Categoría	Direcciones MINEDUC	26 categorías.	Estandarización a MAYÚSCULAS sin tildes.	No (Original)
DEPARTAMENTO_OFICIAL	Departamento geográfico validado.	Categoría	22 deptos de Guatemala	22 categorías oficiales.	Creación mapeando el prefijo real del código (Ej: 00 y 01 unificados en GUATEMALA).	Sí (De CODIGO)
ES_CIUDAD_CAPITAL	Bandera de ubicación en la capital.	Booleana	True, False	2 valores lógicos.	Creada evaluando si el prefijo del código geográfico equivale a 00.	Sí (De CODIGO)
FECHA_EN_DIRECCION	Fechas mal ingresadas en dirección.	Texto	Fechas dd/mm/aaaa o NA	16 fechas únicas.	Extracción automatizada utilizando expresiones regulares desde la dirección.	Sí (De DIRECCION)
TELEFONO_PRINCIPAL	Primer contacto totalmente válido.	Texto	8 dígitos exactos	6,431 números.	Extracción forzosa del primer token de 8 dígitos de la columna original.	Sí (De TELEFONO)

TELEFONO_ADICIONALES	Números de contacto secundarios.	Texto	Bloques de 8 dígitos con ;	94 combinaciones.	Extracción de tokens telefónicos residuales de la variable cruda.	Sí (De TELEFONO)
N_TELEFONOS	Conteo total de contactos usables.	Entero	0 al 4	5 valores (0, 1, 2, 3, 4).	Sumatoria de los tokens telefónicos extraídos. Tipo de dato Pandas int16.	Sí (De TELEFONO)
TELEFONO_VALIDO	Calidad del teléfono capturado.	Booleana	True, False, NA	3 estados posibles.	Bandera si la celda original arrojó al menos un número limpio o era inválido.	Sí (De TELEFONO)
DUP_PARCIAL_SOSPECHOSO	Marca de un posible duplicado.	Booleana	True, False	2 valores lógicos.	Creado si nombre y dirección cruzan >90% de similitud (RapidFuzz) sin cambio de plan.	Sí (Derivación)